

Azərbaycan Dili üçün Avtomatik Nitq Tanıma

Analitik Hesabat — Hissə C

Model: openai/whisper-small

Dataset: Mozilla Common Voice (Azerbaijani)

Fine-tuning: 150 train / 30 val nümunə

Konfigurasiya: 10 epoch, batch=8, lr=1e-5

R.I.S.K. Company — AI Internship Program

May 3, 2026

Contents

1	C1 — Çətinliklər və Həllər	2
1.1	Hansı texniki problemlərlə üzləşdiniz?	2
1.1.1	Az məlumat problemi (Low-Resource Problem)	2
1.1.2	Overfitting	2
1.1.3	Sentence-level data məhdudiyyəti	2
1.1.4	Dil xüsusiyyətlərindən yaranan çətinliklər	2
1.2	Həll yolları	2
1.3	Azərbaycan dilinin xüsusiyyətləri ASR-ı necə çətinləşdirir?	3
2	C2 — Nəticələrin Təhlili	4
2.1	İdə edilən WER/CER nəticəsi yaxşıdır?	4
2.2	Model hansı növ səhvlər edir?	4
2.3	Hansı audio şəraitlərində model daha yaxşı / daha pis işləyir?	5
3	C3 — Yaxşılaşdırma Yolları	6
3.1	Production-a aparmaq üçün nə etmək lazımdır?	6
3.2	Daha çox resurs olsaydı, növbəti 3 addım nə olardı?	6
3.3	Azərbaycan dili üçün ASR-ın ən böyük problemi	6

1. C1 — Çətinliklər və Həllər

1.1. Hansı texniki problemlərlə üzləşdiniz?

Layihə zamanı bir sıra fundamental ASR və machine learning çətinlikləri ilə üzləşildi:

1.1.1. Az məlumat problemi (Low-Resource Problem)

Azərbaycan dili üçün Mozilla Common Voice datasetində cəmi **215 train nümunəsi** mövcuddur - bu, təxminən 8-12 dəqiqəlik audioya bərabərdir. Bu həcm Whisper-in öyrəndiyi ingilis dilinin 438,000 saatlıq datasının yanında əhəmiyyətsiz qalır. Az data ilə fine-tuning zamanı model ya kifayət qədər öyrənmir, ya da train nümunələrini əzbərləyir (overfitting).

1.1.2. Overfitting

150 train nümunəsi ilə aparılan eksperimentlərdə model cəmi **5-6 epoch-dan sonra** overfitting göstərdi: train loss azalmağa davam etdi ($2.62 \rightarrow 0.007$), lakin validation WER artmağa başladı. Bu, modelin Azərbaycan dilini ümumi şəkildə öyrənmək əvəzinə, train nümunələrini əzbərlədiyini göstərir.

1.1.3. Sentence-level data məhdudiyyəti

Common Voice dataseti qısa, izolə edilmiş cümlələrdən ibarətdir. Bu cür data ilə fine-tune edilmiş model uzun audio parçalarında (long-form) performansını itirir - arxiv məqalələrində "*segmentation forgetting*" adlandırılan bu problem real həyat tətbiqlərini çətinləşdirir. Model danışq axınındakı uzun cümlələri düzgün seqmentləşdirə bilmir.

1.1.4. Dil xüsusiyyətlərindən yaranan çətinliklər

Azərbaycan dilinin agglutinativ (yapışqan) quruluşu modelin lüğət öyrənməsini çətinləşdirir. Hər söz kökünə onlarca şəkilçi artırılı bilər - məsələn, "*evlərimizdənmi*" kimi formalar modelin pre-training lüğətində olmayan nadir token-lər yaradır. Bu tokenization problemi WER-i birbaşa artırır.

1.2. Həll yolları

- **Overfitting-ə qarşı:** `load_best_model_at_end=True` ilə validation WER-ə əsasən ən yaxşı checkpoint saxlandı. Training 10 epoch aparılsa da, faktiki olaraq epoch 5-in modeli istifadə edildi.
- **Az datanın effektiv istifadəsi:** `gradient_checkpointing=True` və `fp16=True` ilə yaddaş optimallaşdırıldı, daha böyük batch size sınandı.
- **Dil konfigurasiyası:** `model.generation_config.language = "azerbaijani"` ilə model inference zamanı dil aşkarlamasını atlayaraq birbaşa Azərbaycan dilinə yönəldildi.
- **Tokenization:** `WhisperProcessor` Azərbaycan dili parametrləri ilə yükləndi ki, label encoding düzgün aparılsın.

1.3. Azərbaycan dilinin xüsusiyyətləri ASR-ı necə çətinləşdirir?

Azərbaycan dili bir sıra linqvistik xüsusiyyətlərə görə ASR üçün çətin bir dildir:

- **Agglutinatıv quruluş:** Azərbaycan dili yapışqan dil olduğundan bir söz kökünə çoxsaylı şəkilçi artırılır. Məsələn, “*evlərimizdən*” kimi formalar model üçün nadir leksik vahidlər yaradır.
- **Az miqdarda training data:** Mozilla Common Voice-da Azərbaycan dili üçün cəmi 215 train nümunəsi mövcuddur. Bu, Whisper-in öyrəndiyi ingilis dilinin yüz minlərlə saatı ilə müqayisədə son dərəcə azdır.
- **Latın əlifbasına keçid:** Azərbaycan 1991-ci ildə kiril əlifbasından latın əlifbasına keçib. Bu tarixi keçid rəqəmsal mətnlərin miqdarını azaldır.
- **Dialekt müxtəlifliyi:** Cənubi Azərbaycan və Şimali Azərbaycan dialektləri arasında fərqlər mövcuddur ki, bu da modeli çətinləşdirir.
- **Türk dili qrupuna yaxınlıq:** Whisper-in Azərbaycan dilinə aid pre-training datası az olduğundan model bəzən türk dilinə yaxın nəticələr verir.

2. C2 — Nəticələrin Təhlili

2.1. İdə edilən WER/CER nəticəsi yaxşıdır?

Table 1: Baza model vs. Fine-tuned model müqayisəsi

Model	WER (%)	CER (%)
Baza (whisper-small)	65.32	18.49
Fine-tuned	51.63	12.92
Yaxşılaşma	13.69	5.57

Cavab: Bəli, bu şərtlər daxilində yaxşı nəticədir.
saslandırma:

- Cəmi **150 train nümunəsi** (təxminən 5–10 dəqiqəlik audio) ilə **13.69% WER azalması** əldə edilib.
- Müqayisə üçün: HuggingFace-in rəsmi fine-tuning bələdçisində Hindi dili üçün 8 saat data ilə 31.5% azalma əldə edilib. Bizdə isə 10 dəqiqəlik data ilə 13.69% azalma — nisbətən güclü nəticədir.
- WER 51.63% hələ də yüksəkdir, lakin bu **məhdud data** şəraitinin nəticəsidir, pipeline-in yanlışlığının deyil.
- Daha çox data (1000+ nümunə) ilə WER-in 20–30% səviyyəsinə endirilə biləcəyi gözlənilir.

2.2. Model hansı növ səhvlər edir?

- **Leksik səhvlər:** Model nadir sözləri, xüsusilə şəkilçiləri olan uzun söz formalarını yanlış tanıyır. Məsələn, “*işləyirlər*” əvəzinə “*işləyir*” kimi qısa forma verilə bilər.
- **Fonetik səhvlər:** Azərbaycan dilindəki *ə*, *ö*, *ü*, *ğ* kimi spesifik səslər modelin öyrənmədə çətinlik çəkdiyi hərflərdir.
- **İnsersiya/Silinmə:** Model bəzən sözlər arasında əlavə sözlər əlavə edir və ya qısa funksiya sözlərini buraxır.
- **Overfitting əlaməti:** Epoch 5-dən sonra validation WER artmağa başlayır — model train nümunələrini əzbərləyir, generalizasiya azalır.

Figure 1: Training Loss və Validation WER (epoch üzrə)

Epoch	Train Loss	Val WER (%)	Qeyd
1	2.620	60.75	
2	1.356	57.01	
3	0.688	54.67	
4	0.381	53.27	
5	0.240	52.34	← yaxşı
6	0.164	52.34	
7	0.107	53.27	Overfitting başlayır
8	0.045	53.27	
9	0.011	54.67	
10	0.007	54.67	

2.3. Hansı audio şəraitlərində model daha yaxşı / daha pis işləyir?

- **Daha yaxşı:** Aydın tələffüz, adi sürət, az küy, standart ədəbi Azərbaycan dili, qısa cümlələr.
- **Daha pis:** Arxa plan küyü, sürətli danışq, dialekt sözləri, uzun cümlələr. Bu fine-tuning-in sentence-level data ilə aparılmasından qaynaqlanır — model uzun audio üçün zəifləyir (arxiv məqaləsinin *segmentation forgetting* problemi ilə üst-üstə düşür).

3. C3 — Yaxşılaşdırma Yolları

3.1. Production-a aparmaq üçün nə etmək lazımdır?

1. **Daha çox data:** Minimum 10–50 saat Azərbaycan dili audio datası toplamaq lazımdır. Common Voice-a töhfə vermək və ya AzTV, İctimai TV-dən açıq audio məlumatlar əldə etmək olar.
2. **Daha böyük model:** `whisper-medium` və ya `whisper-large-v3` istifadəsi WER-i əhəmiyyətli dərəcədə azalda bilər.
3. **Long-form audio dəstəyi:** Sentence-level data ilə yanaşı, uzun audio parçaları da training-ə daxil etmək lazımdır ki, model real həyatda işlədilə bilsin.
4. **Data augmentasiyası:** Küy əlavəsi, sürət dəyişikliyi, pitch shift kimi texnikalar az datanı effektiv şəkildə artırmağa bilər.
5. **Serving infrastrukturu:** FastAPI + Docker ilə REST API, ONNX/TensorRT ilə inference optimallaşdırması lazımdır.
6. **Monitoring:** Production-da WER-i real vaxt rejimində izləmək üçün logging sistemi qurulmalıdır.

3.2. Daha çox resurs olsaydı, növbəti 3 addım nə olardı?

1. **Whisper-large-v3 + tam dataset:** Bütün mövcud Azərbaycan dili audio datasını (Common Voice + əlavə mənbələr) `whisper-large-v3` modeli ilə fine-tune etmək. Bu, WER-i 30%-ə qədər endirə bilər.
2. **Data augmentasiyası pipeline:** `audiomentations` kitabxanası ilə küy, reverb, sürət dəyişikliyi tətbiq edərək effektiv dataset həcmi 5–10x artırmaq.
3. **Language Model inteqrasiyası:** Azərbaycan dili üçün n-gram və ya transformer-based language model ilə shallow fusion tətbiq etmək — bu, leksik səhvləri əhəmiyyətli dərəcədə azaldır.

3.3. Azərbaycan dili üçün ASR-in ən böyük problemi

Azərbaycan dili üçün ASR-in ən böyük problemi kifayət qədər annotasiya edilmiş audio datanın olmamasıdır: agglutinativ morfoloji quruluşu nəzərə alındıqda, az datayla öyrədilən model söz formalarının çoxluğunu əhatə edə bilmir.